



案例特训专题

【数据库设计篇】



课程内容提要



- 规范化与反规范化 (★★★)
- 索引与视图 (★★★)
- 分布式数据库 (★★★)
- NoSQL (★★★)
- 内存数据库 (★★★)




考情分析



年份	主题	分值
2018	分布式数据库缓存设计-MemCache和Redis	25分
2019	分布式数据库缓存设计-一致性问题 and 运维	25分
	Web系统架构设计-SQL注入攻击	7分
2020年	分布式数据库缓存设计-Redis	25分
	数据库设计-规范化数据库设计	25分
2021年	数据库设计-规范化与反规范化技术、Redis	25分
2022年	分布式数据库缓存设计-一致性、布隆过滤器	25分
2023年	数据库设计-数据持久层，Redis，读写分离	25分
	大数据架构	25分



数据库设计概述






数据库设计概述



E-R模型






数据库设计概述



概念结构设计



[illegible]

数据流图





案例分析练习题



参考答案：


- (1) 项目管理员
- (2) 项目经理
- (3) 项目指标数据
- (4) ~ (6) 指标参数、项目信息、事故及影响因素参数



数据库设计概述



逻辑结构设计






数据库设计概述



逻辑结构设计

- 目或度：关系模式中属性的个数。
- 候选码（候选键）
- 主码（主键）
- 主属性与非主属性：组成候选码的属性就是主属性，其他的就是非主属性。
- 外码（外键）
- 全码（ALL-Key）：关系模式的所有属性组是这个关系的候选码。
- 简单属性与复合属性、派生属性、多值属性





案例分析练习题



阅读下列说明，回答问题1至问题3，将解答填入答题纸的对应栏内。

【说明】

某企业委托软件公司开发一套包裹信息管理系统，以便于对该企业通过快递收发的包裹信息进行统一管理。在系统设计阶段，需要对不同快递信息的包裹单信息进行建模，其中，邮政包裹单如图 2-1 所示：

国内 快递包裹 详情单 (通知单联)

接收局号码: 邮1106乙

①投通局在 一式四份，通用力填写。

中国邮政 CHINA POST

KA08991879435

收件人	☐ ☐ ☐ ☐ ☐ ☐	内件品名及数量	
	姓名: 电话(手机):		
	单位名称:		
	详细地址:	是否短信回执 ☐ 是 ☐ 否	
寄件人		是否保价 ☐ 是 ☐ 否	收寄人名章:
	姓名: 电话(手机):	保价金额: 元	重量: 克
	单位名称:	寄件人声明: 同意并遵守背面的“使用须知”。如包裹无法投递, 按如下选择处理:	资费: 元
	详细地址:	☐ 退还寄件人 ☐ 抛弃处理	挂号费: 元
		签字:	保价费: 元
	用户代码: 邮政编码:	检查人员名章:	回执费: 元
		总计: 元	

KA 0899-1879 4 35 填写本单前, 务请阅读背面的“使用须知”! 您的签名意味着您理解并接受“使用须知”内容。

图 2-1



案例分析练习题



【问题1】（14分）

请说明关系型数据库开发中，逻辑数据模型设计过程包含哪些任务？该包裹单的逻辑数据模型中应该包含哪些实体？并指出每个关系模式的主键属性。

【问题2】（6分）

请说明什么是超类实体？结合图中包裹单信息，试设计一种超类实体，给出完整的属性列表。

【问题3】（5分）

请说明什么是派生属性？结合图 2-1 中包裹单信息说明哪个属性是派生属性。



案例分析练习题



国内 **快递包裹** 详情单 (通知单联)


中国邮政 CHINA POST

KA08991879435

接收局号码: 邮1106乙

收件人	☐ ☐ ☐ ☐ ☐ ☐	内件品名及数量	收寄人名章:
	姓名: 电话(手机):		
	单位名称:		
	详细地址:	是否短信回执 ☐ 是 ☐ 否	
寄件人		是否保价 ☐ 是 ☐ 否	重量: 克
	姓名: 电话(手机):	保价金额: 元	资费: 元
	单位名称:	寄件人声明: 同意并遵守背面的“使用须知”。如包裹无法投递, 按如下选择处理:	挂号费: 元
	详细地址:	☐ 退还寄件人 ☐ 抛弃处理	保价费: 元
		签字:	回执费: 元
	用户代码: 邮政编码:	检查人员名章:	总计: 元

KA 0899-1879 4 35 填写本单前, 务请阅读背面的“使用须知”! 您的签名意味着您理解并接受“使用须知”内容。



收件人 (姓名, 电话, 单位名称, 详细地址)

寄件人 (姓名, 电话, 单位名称, 详细地址, 用户代码, 邮政编码)

包裹单 (快递单号, 收件人, 发件人, 内件品名及数量, 是否短信回执, 是否保价, 保价金额, 退还处理, 寄件人签字, 检查人员名章, 接收局号码, 收件人名章, 重量, 资费, 挂号费, 保价费, 回执费, 总计)



案例分析练习题



参考答案

【问题1】

逻辑数据模型设计过程包含的任务：

- (1) 构建系统上下文数据模型，包含实体及实体之间的联系；
- (2) 绘制基于主键的数据模型，为每个实体添加主键属性；
- (3) 构建全属性数据模型，为每个实体添加非主键属性；
- (4) 利用规范化技术建立系统规范化数据模型。

包裹单的逻辑数据模型中包含的实体：

- (1) 收件人（主键:电话）；
- (2) 寄件人（主键:电话）；
- (3) 包裹单（主键:编号）。



案例分析练习题



参考答案

【问题2】

超类实体是将多个实体中相同的属性组合起来构造出的新实体。

用户（姓名、电话、单位名称、详细地址）

【问题3】

派生属性是指某个实体的非主键属性由该实体其他非主键属性决定。

包裹单中的总计是由资费、挂号费、保价费、回执费计算得出，所以是派生属性。



数据库设计概述



数据库设计关注的问题：

性能

数据一致性

安全



数据库设计概述



数据库性能优化

集中式数据库优化

硬件系统

CPU, 内存, I/O (硬盘, 阵列), 网络

系统软件

参数, 如进程优先级, CPU使用权, 内存使用

数据库设计

分区、分表、分库

物化视图

索引

常查询-建索引, 常修改-避免索引

SQL优化

以不相干子查询替代相干子查询

应用软件

数据库连接池

只检索需要的列

全局查询树的变换

用带IN的条件子句等价替换OR子句

多副本策略

经常提交COMMIT, 以尽早释放锁

查询树的分解

尽可能减少多表查询

半连接与直接连接

分布式数据库优化

通信代价





规范化与反规范化



数据冗余、插入、修改、删除异常


逐步优化，以解决..



思考：范式级别提升带来了什么负面影响？



规范化与反规范化



技术手段	说明
增加派生性冗余列	已有单价和数量列，增加“总价”列
增加冗余列	已有学号列，增加“姓名”列
重新组表	把拆分的表重新组表
分割表	把用户表作水平分割，长沙的用户存在长沙，上海的用户存在上海



规范化与反规范化



反规范化的**优点**：连接操作少，**检索快，统计快**，需要查的表减少，检索容易。

反规范化的 缺点	解决方案
数据冗余，需要更大存储空间	无解
插入、更新、删除操作开销更大	无解
数据不一致 可能产生添加、修改、删除异常	1、触发器数据同步 2、应用程序数据同步
更新和插入代码更难写	无解



案例分析练习题



阅读以下关于数据库设计的叙述，在答题纸上回答问题1至问题3。

【说明】

某医药销售企业因业务发展，需要建立线上药品销售系统，为用户提供便捷的互联网药品销售服务。该系统除了常规药品展示、订单、用户交流与反馈功能外，还需要提供当前热销产品排名、评价分类管理等功能。通过对需求的分析，在数据管理上初步决定采用关系数据库（MySQL）和数据库缓存（Redis）的混合架构实现。

经过规范化设计之后，该系统的部分数据库表结构如下所示：

供应商（供应商ID，供应商名称，联系方式，供应商地址）；

药品（药品ID，药品名称，药品型号，药品价格，供应商ID）；

药品库存（药品ID，当前库存数量）；

订单（订单号码，药品ID，供应商ID，药品数量，订单金额）。



案例分析练习题



【问题1】（9分）

在系统初步运行后，发现系统数据访问性能较差。经过分析，刘工认为原来数据库规范化设计后，关系表过于细分，造成了大量的多表关联查询，影响了性能。例如当用户查询商品信息时，需要同时显示该药品的信息、供应商的信息、当前库存等信息。

为此，刘工认为可以采用反规范化设计来改造药品关系的结构，以提高查询性能。修改后的药品关系结构为：

药品（药品ID，药品名称，药品型号，药品价格，供应商ID，供应商名称，当前库存数量）；

请用200字以内的文字说明常见的反规范化设计方法，并说明用户查询商品信息应该采用哪种反规范化设计方法。



案例分析练习题



【问题2】（9分）

王工认为，反规范化设计可提高查询的性能，但必然会带来数据的不一致性问题。请用200字以内的文字说明在反规范化设计中，解决数据不一致性问题的三种常见方法，并说明该系统应该采用哪种方法。

【问题3】（7分）

该系统采用了Redis来实现某些特定功能（如当前热销药品排名等），同时将药品关系数据放到内存以提高商品查询的性能，但必然会造成Redis和MySQL的数据实时同步问题。

（1） Redis的数据类型包括String、Hash、List、Set和ZSet等，请说明实现当前热销药品排名的功能应该选择使用哪种数据类型。

（2） 请用200字以内的文字解释说明解决Redis和MySQL数据实时同步问题的常见方案。



案例分析练习题



参考答案：

【问题1】（9分）

常见的反规范化技术包括：

- （1）增加冗余列：增加冗余列是指在多个表中具有相同的列，它常用来在查询时避免连接操作。
- （2）增加派生列：增加派生列指增加的列可以通过表中其他数据计算生成。它的作用是在查询时减少计算量，从而加快查询速度。
- （3）重新组表：重新组表指如果许多用户需要查看两个表连接出来的结果数据，则把这两个表重新组成一个表来减少连接而提高性能。
- （4）分割表：有时对表作分割可以提高性能。

用户查询商品信息应该采用：增加冗余列。

用户查询商品信息时，需要显示药品信息（药品表中），供应商信息（供应商表），库存信息（库存表中），此时查询的是药品表，但表中缺了供应商的信息和库存信息，可以通过增加冗余列的方式把这些信息并过来。以避免连接操作带来的查询性能下降。



案例分析练习题



【问题2】

针对反规范化数据不一致问题，可采用的解决方案包括：

- 1、触发器数据同步。
- 2、应用程序数据同步。
- 3、批处理同步。

本系统应该采用 应用程序数据同步或者触发器数据同步方式。

【问题3】

- (1) 热销药品排名适合用：ZSet，即有序集合类型。
- (2) ①实时同步方案，先查缓存，查不到再从DB查询，并保存到缓存；更新缓存时先更新数据库，再将缓存设置过期。
 - ②异步队列方式同步，可采用消息中间件处理。
 - ③通过数据库插件完成数据同步。
 - ④利用触发器进行缓存同步。



索引与视图



数据库索引：**提升**查询效率；**降低**添加、修改、删除效率；采用B树，B+树等。

数据表

学号	姓名	性别
001	张三	男
102	李四	女
008	王五	男
007	赵六	男
235	钱七	女
417	李华	男
907	张明	女
...	...	...
018	龙四	女



索引表


学号	记录指针
1	data
7	data
8	data
18	data
102	data
235	data
417	data
907	data
...	...



索引与视图



B+树示例





索引与视图



关系的3种类型

- **基本关系**（通常又称为基本表或基表）：实际存在的表，实际存储数据的逻辑表示。
- **查询表**：查询结果对应的表。
- **视图表**：由基表或其他视图表导出的表，本身不独立存储，数据库只存放它的定义，常称为虚表。它是一个虚拟表（逻辑上的表），其内容由查询定义（仅保存SQL查询语句）。同真实的表一样，视图包含一系列带有名称的列和行数据。但是，视图并没有真正存储这些数据，而是通过查询原始表动态生成所需要的数据。



索引与视图



视图 (View) 并不在数据库中实际存在，而是一种**虚拟表**。

学生信息表

学号	姓名	性别
N001	张三	男
N002	李四	女

课程信息表

课程号	课程名	授课老师
C001	数据结构	王老师
C002	Java语言	李老师

选课关系表

学号	课程号	成绩
N001	C001	85
N002	C002	74

学员选课**视图**

学号	课程号	姓名	课程名	成绩
N001	C001	张三	数据结构	85
N002	C002	李四	Java语言	74



索引与视图



视图的**优点**:

- 1、视图能**简化**用户的**操作**;
- 2、视图机制可以使用户以不同的方式查询同一数据;
- 3、视图对数据库重构提供了一定程度的**逻辑独立性**;
- 4、视图可以对机密的数据提供**安全保护**。

物化视图: 将视图的内容物理存储起来, 其数据随原始表变化, 同步更新。

它不是传统意义上虚拟视图, 是实体化视图, 其本身会存储数据。同时当原始表中的数据更新时, 物化视图也会更新。



案例分析练习题



【说明】

某软件企业开发一套类似于淘宝网上商城业务的电子商务网站。该系统涉及多种用户角色，包括购物用户、商铺管理员、系统管理员等。

在数据库设计中，该系统数据库的核心关系包括：

产品（产品编码，产品名称，产品价格，库存数量，商铺编码）

商铺（商铺编码，商铺名称，商铺地址，商铺邮箱，服务电话）

用户（用户编码，用户名称，用户地址，联系电话）

订单（订单编码，订单日期，用户编码，商铺编码，产品编码，产品数量，订单总价）

不同用户角色有不同的数据需求，为此该软件企业在基本数据库关系模式的基础上，定制了许多视图。其中，有很多视图涉及到多表关联和聚集函数运算。



案例分析练习题



【问题1】（8分）

商铺用户需要实时统计本商铺的货物数量和销售情况，以便及时补货，或者为商铺调整销售策略。为此专门设计了可实时查看当天商铺中货物销售情况和存货情况的视图，商铺产品销售情况日报表（商铺编码，产品编码，日销售产品数量，库存数量，日期）。

数据库运行测试过程中，发现针对该视图查询性能比较差，不满足用户需求。

请说明数据库视图的基本概念及其优点，并说明本视图设计导致查询性能较差的原因。



案例分析练习题



【问题2】（8分）

为解决该视图查询性能比较差的问题，张工建议为该数据建立单独的商品当天货物销售、存货情况的关系表。但李工认为张工的方案造成了数据不一致的问题，必须采用一定的手段来解决。

- 1) 说明张工方案是否能够对该视图查询性能有所提升，并解释原因。
- 2) 解释说明李工指出的数据不一致问题产生的原因。

【问题3】（9分）

针对李工提出的问题，常见的解决手段有应用程序实现，触发器实现和物化视图实现等，请用300字以内的文字解释说明这三种方案。



案例分析练习题



参考答案：

【问题1】

视图是虚表，是从一个或几个基本表（或视图）中导出的表，在系统的数据字典中仅存放了视图的定义，不存放视图对应的数据。

视图的优点：

- 1、视图能简化用户的操作
- 2、视图机制可以使用户以不同的方式查询同一数据
- 3、视图对数据库重构提供了一定程度的逻辑独立性
- 4、视图可以对机密的数据提供安全保护

查询性能较差的原因是视图中“日销售产品数量”需要针对订单表作统计分析，订单表中有数量庞大的历史销售记录，所以这种操作极为耗时。



案例分析练习题



【问题2】

- 1) 张工方案能够对该视图查询性能有所提升，因为这样做能极大的减少统计分析的数据量，对小数据量进行统计，性能是能得以保障的。
- 2) 由于当日订单数据既存储在订单表中，又存储在单独的当天货物销售、存货情况表中。同一数据存储了两份，一旦出现修改，未同步修改，则会造成数据不一致。

【问题3】


应用程序实现：在进行订单的添加、修改、删除操作时，从应用程序中，控制对两个数据表都进行相关操作，以保障数据的一致性。

触发器实现：在应用程序中，只对订单表进行操作。但写触发器，当订单表发生变化时，把当日订单内容同步更新到当天货物销售、存货情况表中。

物化视图实现：建立“当天货物销售、存货情况”的物化视图，物化视图会把相应的数据物理存储起来，而且在订单表发生变化时，会自动更新。



分布式数据库





分布式数据库



	分区	分表
共性	1、都针对数据表； 2、都使用了分布式存储； 3、都提升了查询效率； 4、都降低了数据库的频繁I/O压力值。	
差异	逻辑上还是一张表	逻辑上已是多张表




分布式数据库




分区的常见方式


范围分区



哈希分区



列表分区





分布式数据库



分区策略	分区方式	说明
范围分区 【RANGE】	按数据范围值来作分区	例：按用户编号分区，0-999999映射到分区A； 1000000-1999999映射到分区B。
散列分区 【HASH】	通过对key进行hash运算分区	例：可以把数据分配到不同分区，这类似于取余操作，余数相同的，放在一个分区上。
列表分区 【LIST】	根据某字段的某个具体值进行分区	例：长沙用户分成一个区，北京用户一个区



分布式数据库




分区的优点：

- 1、相对于单个文件系统或是硬盘，分区可以存储更多的数据。
- 2、数据管理比较方便，比如要清理或废弃某年的数据，就可以直接删除该日期的分区数据即可。
- 3、精准定位分区查询数据，不需要全表扫描查询，大大提高数据检索效率。
- 4、可跨多个分区磁盘查询，来提高查询的吞吐量。
- 5、在涉及聚合函数查询时，可以很容易进行数据的合并。



分布式数据库






分布式数据库



➤ 分布透明性

- 水平分片：按记录分
- 垂直分片：按字段分
- 混合分片

- 分片透明性：分不分片，用户感受不到（不关心如何分片存储）。
- 位置透明性：数据存放在哪里，用户不用管（用户无需知道数据存放的物理位置）。
- 复制透明：不关心结点的复制情况
- 局部数据模型透明性（逻辑透明）：用户或应用程序无需知道局部场地使用的是哪种数据模型。





分布式数据库



分布式事务管理

两阶段提交协议 2PC

➤ 2PC事务提交的两个阶段

表决阶段，目的是形成一个共同的决定。

执行阶段，目的是实现这个协调者的决定。

➤ 两条全局提交规则

只要有一个参与者撤销事务，协调者就必须做出全局撤销决定。


只有所有参与者都同意提交事务，协调者才能做出全局提交决定。



分布式数据库



分布式事务管理



两阶段提交协议活动图



分布式数据库



➤ 分布式数据库管理系统-组成

- LDBMS
- GDBMS
- 全局数据字典
- 通信管理 (CM)

➤ 分布式数据库管理系统-结构

- 全局控制集中的DDBMS
- 全局控制分散的DDBMS
- 全局控制部分分散的DDBMS



NoSQL



✓ NoSQL (Not-only SQL) : 不仅仅只是SQL，泛指非关系型的数据库。

对比维度	关系数据库	NoSQL
应用领域	面向通用领域	特定应用领域
数据容量	有限数据	海量数据
数据类型	结构化数据【二维表】	非结构化数据
并发支持	支持并发、但性能低	高并发
事务支持	高事务性	弱事务性
扩展方式	向上扩展	向外扩展



NoSQL



分类	典型应用场景	数据模型	优点	缺点	举例
键值 (key-value)	内容缓存，主要用于处理大量数据的高访问负载，也用于一些日志系统等等。	Key 指向 Value 的键值对，通常用hash table来实现	查找速度快	数据无结构化，通常只被当作字符串或者二进制数据	Redis, Tokyo Cabinet/Tyrant, Voldemort, Oracle BDB
列存储数据库	分布式的文件系统	以列簇式存储，将同一列数据存在一起	查找速度快，可扩展性强，更容易进行分布式扩展	功能相对局限	HBase, Cassandra, Riak



NoSQL



分类	典型应用场景	数据模型	优点	缺点	举例
文档型数据库	Web应用（与Key-Value类似，Value是结构化的，不同的是数据库能够了解Value的内容）	Key-Value对应的键值对，Value为结构化数据	数据结构要求不严格，表结构可变，不需要像关系型数据库一样需要预先定义表结构	查询性能不高，而且缺乏统一的查询语法。	CouchDB, MongoDB
图形数据库 (Graph)	社交网络，推荐系统等。专注于构建关系图谱	图结构	利用图结构相关算法。比如最短路径寻址，N度关系查找等	很多时候需要对整个图做计算才能得出需要的信息，而且这种结构不太好做分布式的集群方案。	Neo4J, InfoGrid, Infinite Graph



案例分析练习题



某软件企业开发了一套新闻社交类软件，提供常见的新闻发布、用户关注、用户推荐、新闻点评、新闻推荐、热点新闻等功能，项目采用MySQL数据库来存储业务数据。系统上线后，随着用户数量的增加，数据库服务器的压力不断加大。为此，该企业设立了专门的工作组来解决此问题。

张工提出对MySQL数据库进行扩展，采用读写分离，主从复制的策略，好处是程序改动比较小，可以较快完成，后续也可以扩展到MySQL集群，其方案如图4-1所示。李工认为该系统的诸多功能，并不需要采用关系数据库，甚至关系数据库限制了功能的实现，应该采用NoSQL数据库来替代MySQL，重新构造系统的数据层。而刘工认为张工的方案过于保守，对该系统的某些功能，如关注列表、推荐列表、热搜榜单等实现困难，且性能提升不大；而李工的方案又太激进，工作量太大，短期无法完成，应尽量综合二者的优点，采用Key-Value数据库+MySQL数据库的混合方案。

经过组内多次讨论，该企业最终决定采用刘工提出的方案。



案例分析练习题




图 4-1



案例分析练习题



【问题1】（8分）

张工方案中采用了读写分离，主从复制策略。其中，读写分离设置物理上不同的主/从服务器，让主服务器负责数据的（a）操作，从服务器负责数据的（b）操作，从而有效减少数据并发操作的（c），但却带来了（d）。因此，需要采用主从复制策略保持数据的（e）。

MySQL数据库中，主从复制是通过binary log来实现主从服务器的数据同步，MySQL数据库支持的三种复制类型分别是（f）、（g）、（h）。

请将答案填入（a）～（h）处的空白，完成上述描述。



案例分析练习题



【问题2】（8分）

李工方案中给出了关系数据库与NoSQL数据的比较，如表1所示，以此来说明该新闻社交类软件更适合采用NoSQL数据库。请完成表1中的（a）~（d）处空白。

表1关系数据库与NoSQL数据库特征比较

特征	关系数据库	NoSQL数据库
数据一致性	实时一致性	(a)
数据类型	结构化数据	(b)
事务	高事务性	(c)
水平扩展	弱	强
数据容量	有限数据	(d)



案例分析练习题



【问题3】（9分）

刘工提出的方案采用了Key-Value数据库+MySQL数据库的混合方案，是根据数据的读写特点将数据分别部署到不同的数据库中。但是由于部分数据可能同时存在于两个数据库中，因此存在数据同步问题。请用200字以内的文字简要说明解决该数据同步问题的三种方法。



案例分析练习题



参考答案：

【问题1】

(a) 写 (b) 读 (c) 锁争用 (d) 数据冗余 (e) 一致性
(f) (g) (h) 基于SQL语句的复制 (statement-based replication, SBR) ，基于行的复制 (row-based replication, RBR) ，混合模式复制 (mixed-based replication, MBR)

【问题2】

(a) 最终一致性 (b) 非结构化数据 (c) 柔性事务 (d) 海量数据

【问题3】

- 1、实时同步方案，先查缓存，查不到再从DB查询，并保存到缓存；更新缓存时先更新数据库，再将缓存设置成过期。
- 2、异步队列方式同步，可采用消息中间件处理。
- 3、通过数据库插件完成数据同步。
- 4、利用触发器进行缓存同步。