



案例特训专题

【大数据扩展篇】





课程内容提要



- 大数据技术
 - 大数据处理系统概述
 - Lambda架构
 - Kappa架构
 - Lambda架构与Kappa架构对比和设计选择



大数据架构



大数据特点

5个V：

- ✓ 大规模 (Volume)
- ✓ 高速度 (Velocity)
- ✓ 多样化 (Variety)
- ✓ 价值密度低 (Value)
- ✓ 真实性 (Veracity)

大数据的应用领域：制造业的应用、服务业的应用、交通行业的应用、医疗行业的应用等。



大数据架构



大数据面临着**5个主要问题**，分别是异构性（Heterogeneity）、规模（Scale）、时间性（Timeliness）、复杂性（Complexity）和隐私性（Privacy）。

大数据的研究工作将面临**5个方面的挑战**：

- 挑战一：数据获取问题。
- 挑战二：数据结构问题。
- 挑战三：数据集成问题。
- 挑战四：数据分析、组织、抽取和建模是大数据本质的功能性挑战。
- 挑战五：如何呈现数据分析的结果，并与非技术的领域专家进行交互。



大数据架构



大数据分析的分析步骤大致分为5个主要阶段：


- 
- 数据获取/记录 【实时数据+离线数据】
 - 信息抽取/清洗/注记
 - 数据集成/聚集/表现
 - 数据分析/建模
 - 数据解释



大数据架构



大数据架构发展





大数据架构



挖掘

机器学习和深度学习等技术，
包括tensorflow、caffe、mahout

联机查询OLAP

包括kylin、impala等

随机查询Nosql

包括Hbase、Cassandra 等

计算

主要包括MapReduce、Spark、Flink

存储

主要包括HDFS、Kafka

大数据技术生态

Lambda架构

Kappa 架构

.....



大数据架构



Hbase：分布式、面向列的开源数据库，适合于非结构化数据存储。【实时数据和离线数据均支持】。

HDFS（Hadoop分布式文件系统）：适合运行在通用硬件上的分布式文件系统（Distributed File System）。HDFS是一个高度容错性的系统，适合部署在廉价的机器上。HDFS能提供高吞吐量的数据访问，非常适合大规模数据集上的应用，【通常用于处理离线数据的存储】。

Flume：高可用/可靠，分布式海量日志采集、聚合和传输的系统，Flume支持在日志系统中定制各类数据发送方，用于收集数据；同时，Flume提供对数据进行简单处理，并写到各种数据接受方（可定制）的能力。


Kafka：一种高吞吐量的分布式发布订阅消息系统，它可以处理消费者在网站中的所有动作流数据。

ZooKeeper：开放源码的分布式应用程序协调服务，是Hadoop和Hbase的重要组件。它是一个为分布式应用提供一致性服务的软件，提供的功能包括：配置维护、域名服务、分布式同步、组服务等。



Lambda架构

Lambda架构





大数据架构

Lambda架构




优点	缺点
(1) 容错性好。 (2) 查询灵活度高。 (3) 易伸缩。 (4) 易扩展。	(1) 全场景覆盖带来的编码开销。 (2) 针对具体场景重新离线训练一遍益处不大。 (3) 重新部署和迁移成本很高。



大数据架构



Kappa架构



- 输入数据直接由实时层的实时数据处理引擎对源源不断的源数据进行处理；
- 再由服务层的服务后端进一步处理以提供上层的业务查询。
- 而中间结果的数据都是需要存储的，这些数据包括历史数据与结果数据，统一存储在存储介质中。



大数据架构



Kappa架构


优点	缺点
(1) 将实时和离线代码统一起来了。 (2) 方便维护而且统一了数据口径。 (3) 避免了Lambda架构中与离线数据合并的问题。	(1) 消息中间件缓存的数据量和回溯数据有性能瓶颈。 (2) 在实时数据处理时，遇到大量不同的实时流进行关联时，非常依赖实时计算系统的能力，很可能因为数据流先后顺序问题，导致数据丢失。 (3) Kappa 在抛弃了离线数据处理模块的时候，同时抛弃了离线计算更加稳定可靠的特点。



Kappa架构



Kappa+架构






大数据架构



对比内容	Lambda架构	Kappa架构
复杂度与开发、维护成本	需要维护 两套系统（引擎） ，复杂度高，开发、维护成本高	只需要维护 一套系统（引擎） ， 复杂度低 ，开发、 维护成本低
计算开销	需要一直运行批处理和实时计算， 计算开销大	必要时进行全量计算， 计算开销相对较小
实时性	满足实时性	满足实时性
历史数据处理能力	批式全量处理，吞吐量大，历史数据处理能力强	流式全量处理，吞吐量相对较低，历史数据处理能力相对较弱
使用场景	直接支持批处理，更适合对 历史数据分析查询的场景 ，期望尽快得到分析结果，批处理可以更直接高效地满足这些需求	不是Lambda的替代架构 ，而是简化，Kappa放弃了对批处理的支持，更擅长业务本身为增量数据写入场景的分析需求
选择依据	□根据两种架构对比分析，将业务需求、技术要求、系统复杂度、开发维护成本和历史数据处理能力作为选择考虑因素。 □计算开销虽然存在一定差别，但是相差不是很大，所以不作为考虑因素。	



大数据架构




某网奥运中的
Lambda架构

- 在数据展现层用户可以通过调用数据计算层的相应接口，简单快速进行算法编程，从而呈现出**当日概览**、**赛事回顾**等模块的信息。
- 当日概览模块通过实时计算引擎中的 Spark Streaming，计算直播实时在线人数、地域和频道分布等信息，并实时呈现到前端界面中。在合并计算中查询网站的综合浏览量、页面停留时间、视频的播放次数和平均播放时间等增量数据。
- 而对赛事回顾模块需要呈现的自定义时间段内的历史最高在线人数、逐日播放走势、直播最高在线人数和点播视频排行等数据的统计信息，可以使用**离线计算模块查询这种不断追加的离线数据**。



大数据架构



某证券大数据系统Kappa架构

- 实时日志分析平台基于Kappa架构；
- 使用统一的数据处理引擎Flink可实时处理全部数据；
- 并将其存储到 Elastic-Search 与 OpenTSDB 中。



大数据架构



【说明】

作为行业领先的外卖平台，某电商在云计算、大数据以及算法平台做了许多创新性的工作。某电商外卖平台接入了众多商家，如何根据用户实时的点击、出价以及广告的曝光，商家实时的出价数据，计算出合适的报价数据和算法的决策参数，使得广告主的利益最大化，是一个关键的问题。因此，某电商决定依托大数据平台强大的数据处理、分析能力，创新打造智能决策大数据系。公司成立了专门的项目团队进行研发，要求该平台集业务实时监控、实时计算，故障快速定位与预警于一体，可支持自动化分析当前实时流数据，实时计算并更新算法模型，并且支持多种算法框架和故障快速恢复等功能。

【问题1】（12分）

- 1、常见的大数据架构有Kappa架构与Lambda架构两种，对比这两种架构的特点。
- 2、技术负责人张工决定基于Kappa架构进行设计，用300字以内的文字简要说明张工对比选择Kappa架构的原因。



大数据架构



对比内容	Lambda架构	Kappa架构
复杂度与开发、维护成本	需要维护两套系统（引擎），复杂度高，开发、维护成本高	(1)
计算开销	(2)	必要时进行全量计算，计算开销相对较小
实时性	满足实时性	(3)
历史数据处理能力	批式全量处理，吞吐量大，历史数据处理能力强	(4)



大数据架构



【问题2】（10分）

该智能决策大数据系统架构图如下，请根据下面的（a）～（k）的相关技术；判断这些技术属于架构图的哪个部分，补充完善下图1的（1）-（10）的空白处。

（a）数据采集层；（b）存储计算层；（c）逻辑处理层；（d）应用层；（e）日志库Hive；
（f）实时计算Tair；（g）任务提交基于Flink；（h）决策结果展示；（i）结果本地存储；
（j）B端实时流数据；（k）kafka缓存；（l）计算集群CDH

【问题3】（3分）


实时智能决策大数据平台基于Kappa架构，使用统一的数据处理引擎Flink可实时处理流数据，并将其存储到Hive与Tair中，以供后续决策服务的使用。实时处理的过程如下：一是数据采集；二是数据的清洗与聚合；三是数据存储。请用300字以内的文字简要介绍本题实时处理各个过程的任务。



大数据架构



- (a) 数据采集层;
- (b) 存储计算层;
- (c) 逻辑处理层;
- (d) 应用层;
- (e) 日志库Hive;
- (f) 实时计算Tair;
- (g) 任务提交基于Flink;
- (h) 决策结果展示;
- (i) 结果本地存储;
- (j) B端实时流数据;
- (k) kafka缓存;
- (l) 计算集群CDH



某电商智能决策大数据系统架构



大数据架构



答案

【问题1】

1、（8分，每空2分）

- （1）只需要维护一套系统（引擎），复杂度低，开发、维护成本低
- （2）需要一直运行批处理和实时计算，计算开销大
- （3）满足实时性
- （4）流式全量处理，吞吐量相对较低，历史数据处理能力相对较弱

2、（4分，2条满分）

- （1）Kappa架构只需要维护一套系统（引擎），复杂度相对较低，
 - （2）Kappa架构开发、维护成本系相对较低
 - （3）本系统可以使用Flink 计算引擎，对于Hadoop、Spark、Strom 等关键技术没有强制性依赖。
 - （4）本系统根据用户实时的点击、出价以及广告的曝光进行分析，关注的主要是实时数据，数据集规模不大，流处理系统完全可以使用，应该选择Kappa架构。
- 综上，本系统选择基于Kappa架构实现。




大数据架构



【问题2】（每空1分）

- (1) (c) 逻辑处理层
- (2) (b) 存储计算层
- (3) 或 (4)
- (h) 决策结果展示或 (i) 结果本地存储;
- (5) (j) B端实时流数据
- (6) (k) kafka缓存;
- (7) (g) 任务提交基于Flink;
- (8) (l) 计算集群CDH
- (9) (e) 日志库Hive
- (10) (f) 实时计算Tair;



某电商智能决策大数据系统架构



大数据架构



【问题3】（每条1分）

实时智能决策大数据平台基于Kappa架构，使用统一的数据处理引擎Flink可实时处理流数据，并将其存储到Hive与Tair中，以供后续决策服务的使用。实时处理的过程如下：

一是数据采集，即B端系统会实时收集用户的点击，下单以及广告的曝光和出价数据并输出到Kafka缓存。

二是数据的清洗与聚合，即基于大数据计算集群Flink计算框架，实时读取Kafka中的实时流数据，过滤出需要参与计算的字段，根据业务需求，聚合指定时间端的数据并转换成指标。

三是数据存储，即将Flink计算得到数据存储到Hive日志库中，需要参与模型计算的字段存储到Tair分布式缓存中。